

# Notes on Linear Systems and Matrix Decompositions

Gyubeom Edward Im\*

February 8, 2024

## Contents

<b>1</b>	<b>Linear equation</b>	<b>3</b>
<b>2</b>	<b>Linear system</b>	<b>3</b>
2.1	Homogeneous equation . . . . .	3
2.2	Over-determined system . . . . .	3
2.3	Under-determined system . . . . .	4
<b>3</b>	<b>LU decomposition</b>	<b>4</b>
3.1	PLU decomposition . . . . .	4
3.2	LDU decomposition . . . . .	5
<b>4</b>	<b>Cholesky decomposition</b>	<b>5</b>
4.1	Detailed explanation . . . . .	5
4.2	LDLT decomposition . . . . .	5
<b>5</b>	<b>QR decomposition</b>	<b>5</b>
5.1	Detailed explanation . . . . .	6
5.2	QR decomposition on least squares problem . . . . .	6
<b>6</b>	<b>Eigen decomposition</b>	<b>7</b>
<b>7</b>	<b>Single value decomposition</b>	<b>7</b>
7.1	Computing SVD . . . . .	7
7.2	Range and nullspace of SVD . . . . .	8
7.3	SVD on under-determined system . . . . .	8
7.4	SVD on over-determined system . . . . .	8
<b>8</b>	<b>Pseudo inverse</b>	<b>8</b>
8.1	Pseudo inverse on under-determined system . . . . .	8
8.2	Pseudo inverse on over-determined system . . . . .	9
8.3	SVD of pseudo inverse . . . . .	9
8.3.1	Full column rank case . . . . .	10
8.3.2	Full row rank case . . . . .	10
8.3.3	Rank deficient case . . . . .	10
8.4	QR decomposition of pseudo inverse when singular case . . . . .	11
<b>9</b>	<b>Sherman-Morrison formula</b>	<b>11</b>
9.1	Recursive least squares . . . . .	12
<b>10</b>	<b>Matrix inversion lemma</b>	<b>12</b>
10.1	Derivation of matrix inversion lemma . . . . .	13
10.1.1	LDU decomposition . . . . .	13
10.1.2	UDL decomposition . . . . .	13
10.1.3	Back to matrix inversion lemma . . . . .	14

---

\*blog: [alida.tistory.com](https://alida.tistory.com), email: [gyurse@gmail.com](mailto:gyurse@gmail.com)

---

<b>11 Reference</b>	<b>14</b>
<b>12 Revision log</b>	<b>14</b>

## 1 Linear equation

선형방정식 (Linear Equation)은 변수  $x_1, \dots, x_n$ 이 있을 때 다음과 같이 작성할 수 있는 방정식을 의미한다.

$$a_1x_1 + a_2x_2 + \dots + a_nx_n = b \quad (1)$$

이 때,  $b$ 는 계수를 의미하고  $a_1, \dots, a_n$  값들은 실수 또는 복소수의 미지수를 의미한다. 위 식은 다음과 같이 간결하게 작성할 수 있다.

$$\mathbf{a}^T \mathbf{x} = b \quad (2)$$

이 때,  $\mathbf{a} = \begin{bmatrix} a_1 \\ \vdots \\ a_n \end{bmatrix}$  이고  $\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$  이다.

## 2 Linear system

**선형방정식(linear equation)의 집합을 선형시스템(linear system)이라고 한다.**  $n$ 개의 선형방정식  $\mathbf{a}_1\mathbf{x} = b_1, \dots, \mathbf{a}_n\mathbf{x} = b_n$  이 있는 경우 이를 다음과 같이 간결하게 선형시스템으로 표현할 수 있다.

$$\mathbf{Ax} = \mathbf{b} \quad (3)$$

즉,  $\mathbf{Ax} = \mathbf{b}$  형태의 행렬과 벡터의 방정식을 선형시스템이라고 한다. 선형시스템은 다른 말로 비동차방정식이라고도 불린다. 동차방정식, 비동차방정식의 정의는 다음과 같다.

### 2.1 Homogeneous equation

동차방정식(homogeneous equation)은  $\mathbf{A} \in \mathbb{R}^{n \times m}, \mathbf{x} \in \mathbb{R}^{m \times 1}, \mathbf{b} \in \mathbb{R}^{m \times 1}$  일 때,  $\mathbf{Ax} = \mathbf{0}$  형태의 시스템을 말한다. 0이 아닌 해가 존재한다. 이와 반대로  $\mathbf{Ax} = \mathbf{b}$  형태의 방정식을 비동차방정식(non-homogeneous equation)이라고 한다. 비동차방정식은 해가 존재하지 않거나 여러 개 존재한다.

### 2.2 Over-determined system

$(m > n)$  Overdetermined System

**Over-determined 시스템은 방정식의 개수가 미지수의 개수보다 많은 경우를** 의미한다.  $\mathbf{Ax} = \mathbf{b}$  의 형태에서  $\mathbf{A} \in \mathbb{R}^{m \times n}, \mathbf{x} \in \mathbb{R}^{n \times 1}, \mathbf{b} \in \mathbb{R}^{m \times 1}$  이라고 했을 때  $m > n$  인 경우를 의미한다. Over-determined 시스템의 경우 해가 존재하지 않으며 full column rank를 가진다.

$\mathbf{Ax} = \mathbf{b}$  시스템의 해가 존재하지 않으므로  $\|\mathbf{Ax} - \mathbf{b}\|$ 을 최소화하는 근사해를 구하는 방법을 주로 사용한다.

## 2.3 Under-determined system

$$\begin{array}{ccc}
 & n & 1 \\
 m & \boxed{\mathbf{A} \in \mathbb{R}^{m \times n}} & \boxed{\mathbf{b}} \\
 & n & 1 \\
 & \mathbf{x} & 
 \end{array}
 =
 \begin{array}{ccc}
 & 1 & \\
 m & \boxed{\mathbf{b}} & \\
 & 1 & 
 \end{array}$$

( $m < n$ ) Underdetermined System

**Under-determined 시스템의 경우 방정식의 개수보다 미지수의 개수가 많은 경우**를 의미한다. 즉, over-determined 시스템과 반대로  $n > m$  인 경우를 의미한다. Under-determined 시스템의 경우 무수히 많은 해가 존재하며 full row rank를 가진다.

$\mathbf{Ax} = \mathbf{b}$  시스템이 무수히 많은 해를 가지므로  $\|\mathbf{x}\|^2$  가 최소가 되는 해를 구하는 방법을 주로 사용한다.

## 3 LU decomposition

LU 분해는  $\mathbf{Ax} = \mathbf{b}$  의 시스템에서 행렬  $\mathbf{A}$ 를 하삼각(lower-triangle) 행렬  $\mathbf{L}$  과 상삼각(upper-triangle) 행렬  $\mathbf{U}$ 의 곱으로 분해하는 방법이다.

$$\mathbf{A} = \mathbf{LU} = \mathbf{b} \quad (4)$$

LU 분해를 사용하면 다음과 같이 방정식이 변형된다.

$$\mathbf{Ax} = (\mathbf{LU})\mathbf{x} \quad (5)$$

이를 사용하여 [1]  $\mathbf{Ly} = \mathbf{b}$  방정식을 먼저 푼 후, [2]  $\mathbf{Ux} = \mathbf{y}$  를 순차적으로 계산할 수 있다. tridiagonal, band-diagonal 시스템에 효과적으로 사용할 수 있다.

$$\begin{aligned}
 \mathbf{L}(\mathbf{Ux}) &= \mathbf{b} \\
 \mathbf{Ly} &= \mathbf{b} \quad \cdots [1] \\
 \mathbf{Ux} &= \mathbf{y} \quad \cdots [2]
 \end{aligned} \quad (6)$$

위와 같이 행렬  $\mathbf{A}$ 를  $\mathbf{L}, \mathbf{U}$ 로 분해하면  $\mathbf{x}$ 를 두 스텝에 걸쳐 구해야하지만 삼각행렬의 특성 상  $\mathbf{x}$ 를 구하는 것이 훨씬 더 간단해진다.

### 3.1 PLU decomposition

만약  $\mathbf{A}$ 가 아래와 같은 3x3 행렬이라고 가정해보자.

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^T \\ \mathbf{a}_2^T \\ \mathbf{a}_3^T \end{bmatrix} = \begin{bmatrix} 0 & * & * \\ * & * & * \\ * & * & * \end{bmatrix} \quad (7)$$

LU 분해는 가우스 조던 소거법으로  $\mathbf{L}$ 을 구하기 때문에 만약  $\mathbf{A}$ 의 첫 번째 원소가 0으로 시작하는 경우 정상적으로 분해할 수 없다. 따라서 첫번째 행과 두번째 행의 순서를 변환하는 permutation 행렬  $\mathbf{P}$ 를 앞에 곱해줘야 LU 분해를 수행할 수 있다.

$$\mathbf{PA} = \begin{bmatrix} & 1 & \\ 1 & & \\ & & 1 \end{bmatrix} \mathbf{A} = \begin{bmatrix} \mathbf{a}_2^T \\ \mathbf{a}_1^T \\ \mathbf{a}_3^T \end{bmatrix} = \begin{bmatrix} * & * & * \\ 0 & * & * \\ * & * & * \end{bmatrix} \quad (8)$$

permutation 행렬은 직교행렬이고 직교행렬의 특성 상  $\mathbf{P} = \mathbf{P}^T = \mathbf{P}^{-1}$ 이므로 이를 넘긴 후 전개하면 다음과 같다.

$$\mathbf{A} = \mathbf{PLU} \quad (9)$$

이와 같이 행벡터의 순서를 변경하는  $\mathbf{P}$ 를 곱한 후 LU 분해를 수행하는 방법을 PLU 분해라고 한다.

### 3.2 LDU decomposition

LU 분해에서  $\mathbf{L}, \mathbf{D}$  행렬의 대각 성분을 1로 만들기 위해 중앙에 대각행렬  $\mathbf{D}$ 를 별도로 분해하는 방법을 LDU 분해라고 한다. 따라서 모든 LU 행렬은 LDU 행렬로 분해할 수 있다.

$$\mathbf{A} = \mathbf{L}\mathbf{U} = \mathbf{L}'\mathbf{D}\mathbf{U}' \quad (10)$$

## 4 Cholesky decomposition

Cholesky 분해는  $\mathbf{A}\mathbf{x} = \mathbf{b}$  시스템에서  $\mathbf{A}$ 가 대칭행렬이면서 동시에 positive(-semi) definite인 경우에 이를 하삼각(lower-triangle) 행렬  $\mathbf{L}$ 의 곱으로 분해하는 방법을 말한다.

$$\mathbf{A} = \mathbf{L}\mathbf{L}^T \quad (11)$$

Cholesky 분해는 수치적으로 안정하다는 특징이 있다.

### 4.1 Detailed explanation

임의의 3x3 대칭행렬  $\mathbf{A}$ 가 주어졌다고 하자. 이를 cholesky 분해하면 다음과 같다.

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{21} & a_{22} & a_{32} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \mathbf{L}\mathbf{L}^T = \begin{bmatrix} l_{11} & & \\ l_{21} & l_{22} & \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & l_{31} \\ & l_{22} & l_{32} \\ & & l_{33} \end{bmatrix} \quad (12)$$

$\mathbf{L}\mathbf{L}^T$ 을 자세히 전개하면 다음과 같다.

$$\begin{bmatrix} l_{11} & & \\ l_{21} & l_{22} & \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & l_{31} \\ & l_{22} & l_{32} \\ & & l_{33} \end{bmatrix} = \begin{bmatrix} l_{11}^2 & l_{21}l_{11} & l_{31}l_{11} \\ l_{21}l_{11} & l_{21}^2 + l_{22}^2 & l_{31}l_{21} + l_{32}l_{22} \\ l_{31}l_{11} & l_{31}l_{21} + l_{32}l_{22} & l_{31}^2 + l_{32}^2 + l_{33}^2 \end{bmatrix} \quad (13)$$

이를 통해 일대일로 비교하면  $\mathbf{L}$ 의 원소는 다음과 같이 구할 수 있다.

$$\begin{aligned} l_{11} &= \sqrt{a_{11}} \quad \cdots \text{ up to sign} \\ l_{21} &= a_{21}/l_{11} \\ l_{31} &= a_{31}/l_{11} \\ l_{22} &= \sqrt{a_{22} - l_{21}^2} \\ l_{32} &= (a_{32} - l_{31}l_{21})/l_{22} \\ l_{33} &= \sqrt{a_{33} - l_{31}^2 - l_{32}^2} \end{aligned} \quad (14)$$

이를 임의의 행렬에 대해 일반화하여 표현하면 다음과 같다.

$$\begin{aligned} l_{ii} &= \sqrt{a_{ii} - \sum_{k=1}^{i-1} l_{ik}^2} \\ l_{ij} &= \frac{1}{l_{jj}} \left( a_{ij} - \sum_{k=1}^{j-1} l_{ik}l_{jk} \right) \end{aligned} \quad (15)$$

### 4.2 LDLT decomposition

Cholesky 분해에서  $\mathbf{L}$  행렬의 대각 성분을 1로 만들기 위해 중앙에 대각행렬  $\mathbf{D}$ 를 별도로 분해하는 방법을 LDLT 분해라고 한다. 따라서 모든 cholesky 행렬은 LDLT 행렬로 분해할 수 있다.

$$\mathbf{A} = \mathbf{L}\mathbf{L}^T = \mathbf{L}'\mathbf{D}\mathbf{L}'^T \quad (16)$$

## 5 QR decomposition

QR 분해는  $\mathbf{A}\mathbf{x} = \mathbf{b}$  시스템에서 행렬  $\mathbf{A}$ 를 직교(orthogonal) 행렬  $\mathbf{Q}$ 와 상삼각(upper-triangle) 행렬  $\mathbf{R}$ 의 곱으로 분해하는 방법을 말한다.

$$\mathbf{A} = \mathbf{Q}\mathbf{R} \quad (17)$$

$\mathbf{Q}$ 가 직교 행렬이므로  $\mathbf{Q}\mathbf{Q}^T = \mathbf{I}$ 의 성질을 지닌다. 일반적으로 QR 분해는 LU 분해보다 느리지만 최소제곱법(least squares) 문제를 풀 때 효율적이어서 자주 사용된다.

## 5.1 Detailed explanation

임의의 3x3 행렬  $\mathbf{A}$ 가 주어졌을 때 이를 열벡터로 표현하면 다음과 같다. 자세한 내용은 해당 강의를 참고하면 된다.

$$\mathbf{A} = [\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3] \quad (18)$$

해당 행렬에 gram-schmidt 직교화를 수행하면 임의의 직교행렬  $\mathbf{Q}$ 를 만들 수 있다.

$$\mathbf{Q} = [\mathbf{q}_1, \mathbf{q}_2, \mathbf{q}_3] \quad (19)$$

이 때, gram-schmidt 직교화의 특성 상  $\mathbf{q}_1$ 은 첫번째 열벡터와 동일한 단위 벡터이고  $\mathbf{q}_2$ 는  $\mathbf{q}_1$ 와 직교한 단위벡터이며  $\mathbf{q}_3$ 는  $\mathbf{q}_1, \mathbf{q}_2$ 와 직교한 단위벡터이다. 이를 통해  $\mathbf{a}_i$ 를 구할 수 있다.

$$\begin{aligned} \mathbf{a}_1 &= \mathbf{a}_1^\top \mathbf{q}_1 \cdot \mathbf{q}_1 \\ \mathbf{a}_2 &= \mathbf{a}_2^\top \mathbf{q}_1 \cdot \mathbf{q}_1 + \mathbf{a}_2^\top \mathbf{q}_2 \cdot \mathbf{q}_2 \\ \mathbf{a}_3 &= \mathbf{a}_3^\top \mathbf{q}_1 \cdot \mathbf{q}_1 + \mathbf{a}_3^\top \mathbf{q}_2 \cdot \mathbf{q}_2 + \mathbf{a}_3^\top \mathbf{q}_3 \cdot \mathbf{q}_3 \end{aligned} \quad (20)$$

이를 행렬 형태로 표현하면 다음과 같은 상삼각  $\mathbf{R}$  행렬을 얻을 수 있다.

$$\begin{aligned} [\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3] &= [\mathbf{q}_1, \mathbf{q}_2, \mathbf{q}_3] \begin{bmatrix} \mathbf{a}_1^\top \mathbf{q}_1 & \mathbf{a}_2^\top \mathbf{q}_1 & \mathbf{a}_3^\top \mathbf{q}_1 \\ & \mathbf{a}_2^\top \mathbf{q}_2 & \mathbf{a}_3^\top \mathbf{q}_2 \\ & & \mathbf{a}_3^\top \mathbf{q}_3 \end{bmatrix} \\ \mathbf{A} &= \mathbf{Q}\mathbf{R} \\ \mathbb{R}^{3 \times 3} &= \mathbb{R}^{3 \times 3} \mathbb{R}^{3 \times 3} \end{aligned} \quad (21)$$

임의의 직사각 행렬에 대해서도 QR 분해를 수행할 수 있다. 만약 5x3 행렬  $\mathbf{A}$ 가 주어졌을 때 이는 다음과 같이 QR 분해된다.

$$\begin{aligned} [\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3] &= [\mathbf{q}_1, \mathbf{q}_2, \mathbf{q}_3, \mathbf{q}_4, \mathbf{q}_5] \begin{bmatrix} \mathbf{a}_1^\top \mathbf{q}_1 & \mathbf{a}_2^\top \mathbf{q}_1 & \mathbf{a}_3^\top \mathbf{q}_1 \\ & \mathbf{a}_2^\top \mathbf{q}_2 & \mathbf{a}_3^\top \mathbf{q}_2 \\ & & \mathbf{a}_3^\top \mathbf{q}_3 \\ & & & \\ & & & & \end{bmatrix} \\ \mathbf{A} &= \mathbf{Q}\mathbf{R} \\ \mathbb{R}^{5 \times 3} &= \mathbb{R}^{5 \times 5} \mathbb{R}^{5 \times 3} \end{aligned} \quad (22)$$

$\mathbf{q}_4, \mathbf{q}_5$  벡터는 곱셈에 의해 0이 되어서 실제  $\mathbf{A}$  행렬에는 관여하지 않는다.

## 5.2 QR decomposition on least squares problem

Over-determined 시스템  $\mathbf{Ax} = \mathbf{b}$ 가 주어졌을 때 이에 대한 최적해는 다음과 같이 최소제곱법을 통해 구할 수 있다.

$$\begin{aligned} \min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2^2 \\ \mathbf{x} &= (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} \end{aligned} \quad (23)$$

최소제곱법을 QR 분해를 통해 해석해보자. 임의의 직사각 행렬  $\mathbf{A}$ 를 QR 분해해보면 다음과 같다.

$$\begin{aligned} \mathbf{A} &= \mathbf{Q}\mathbf{R} \\ &= [\mathbf{Q}_1 \quad \mathbf{Q}_2] \begin{bmatrix} \mathbf{R}_1 \\ \mathbf{0} \end{bmatrix} \end{aligned} \quad (24)$$

$\|\mathbf{Ax} - \mathbf{b}\|_2^2$ 를 QR 분해해보면 다음과 같다.

$$\begin{aligned} \|\mathbf{Ax} - \mathbf{b}\|_2^2 &= \|\mathbf{Q}\mathbf{R}\mathbf{x} - \mathbf{b}\|_2^2 \\ &= \|\mathbf{Q}(\mathbf{R}\mathbf{x} - \mathbf{Q}^\top \mathbf{b})\|_2^2 \\ &= \|\mathbf{R}\mathbf{x} - \mathbf{Q}^\top \mathbf{b}\|_2^2 \\ &= \left\| \begin{bmatrix} \mathbf{R}_1 \\ \mathbf{0} \end{bmatrix} \mathbf{x} - \begin{bmatrix} \mathbf{Q}_1^\top \\ \mathbf{Q}_2^\top \end{bmatrix} \mathbf{b} \right\|_2^2 \end{aligned} \quad (25)$$

위 식에서 세번째 줄은  $\|\mathbf{Q}(\cdot)\|_2^2 = (\cdot)^T \mathbf{Q}^T \mathbf{Q}(\cdot) = (\cdot)^T (\cdot) = \|\cdot\|_2^2$ 을 통해 구할 수 있다. 네번째 줄은  $\mathbf{QR}$  행렬을 블록 행렬  $\mathbf{Q}_i, \mathbf{R}_i$ 로 표현한 모습이다. 벡터의 제곱의 합은 선형성을 가지므로 위 식의 마지막 줄을 전개하면 다음과 같다.

$$\left\| \begin{bmatrix} \mathbf{R}_1 \\ \mathbf{0} \end{bmatrix} \mathbf{x} - \begin{bmatrix} \mathbf{Q}_1^T \\ \mathbf{Q}_2^T \end{bmatrix} \mathbf{b} \right\|_2^2 = \|\mathbf{R}_1 \mathbf{x} - \mathbf{Q}_1^T \mathbf{b}\|_2^2 + \|\mathbf{Q}_2^T \mathbf{b}\|_2^2 \quad (26)$$

따라서  $\min_{\mathbf{x}} \left( \|\mathbf{R}_1 \mathbf{x} - \mathbf{Q}_1^T \mathbf{b}\|_2^2 + \|\mathbf{Q}_2^T \mathbf{b}\|_2^2 \right)$ 를 최소화하는  $\mathbf{x}$ 는 다음과 같이 구할 수 있다.

$$\mathbf{x} = \mathbf{R}^{-1} \mathbf{Q}^T \mathbf{b} \quad (27)$$

이 때, 최소제곱법 식의 크기는  $\|\mathbf{Q}_2^T \mathbf{b}\|_2^2$ 이다.

## 6 Eigen decomposition

정방행렬  $\mathbf{A} \in \mathbb{R}^{n \times n}$ 가 대각화 가능한 경우 다음과 같은 두 행렬  $\mathbf{V} \in \mathbb{R}^{n \times n}$ 과 대각행렬  $\mathbf{D} \in \mathbb{R}^{n \times n}$ 에 대하여  $\mathbf{A}$ 를 다음과 같이 분해할 수 있다.

$$\mathbf{A} = \mathbf{V} \mathbf{D} \mathbf{V}^{-1} \quad (28)$$

이를 행렬  $\mathbf{A}$ 에 대한 고유값 분해(eigen decomposition) 라고 한다. 행렬  $\mathbf{A}$ 가 대각화 가능하다는 의미는 행렬  $\mathbf{A}$ 가 고유값 분해 가능하다는 말과 동치이다.

행렬  $\mathbf{A}$ 가 대각화(고유값분해)되기 위해서는 역행렬이 존재하는 행렬  $\mathbf{V}$ 가 존재해야 한다. 행렬  $\mathbf{V}$ 가 역행렬이 존재하기 위해서는  $\mathbf{V}$ 는 행렬  $\mathbf{A}$ 와 같은  $\mathbb{R}^{n \times n}$  크기의 정방행렬이어야 하고  $n$ 개의 선형독립인 열 벡터를 가지고 있어야 한다. 이 때,  $\mathbf{V}$ 의 각 열은 행렬  $\mathbf{A}$ 의 고유벡터가 된다. 만약 행렬  $\mathbf{V}$ 가 존재하는 경우 행렬  $\mathbf{A}$ 는 대각화(고유값분해) 가능하다고 한다.

## 7 Single value decomposition

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^T =$$

( $\mathbf{A} \in \mathbb{R}^{m \times n}$ )

The diagram shows three matrices:  $\mathbf{U}$  (size  $m \times m$ ),  $\mathbf{D}$  (size  $m \times n$ ), and  $\mathbf{V}^T$  (size  $n \times n$ ). The dimensions are labeled as follows:  $\mathbf{U}$  has  $m$  on the left and  $m$  on the top;  $\mathbf{D}$  has  $m$  on the left and  $n$  on the top;  $\mathbf{V}^T$  has  $n$  on the left and  $n$  on the top.

행렬  $\mathbf{A} \in \mathbb{R}^{n \times m}$ 이 주어졌을 때 특이값 분해(Singular Value Decomposition, SVD)는 다음과 같이 나타낼 수 있다.

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T \quad (29)$$

이 때,  $\mathbf{U} \in \mathbb{R}^{m \times m}$ ,  $\mathbf{V} \in \mathbb{R}^{n \times n}$ 인 행렬이며 이들은 각 열이 Col  $\mathbf{A}$ 와 Row  $\mathbf{A}$ 에 의 정규직교기저벡터(Orthonormal Basis)로 구성되어 있다.  $\mathbf{\Sigma} \in \mathbb{R}^{m \times n}$ 은 대각행렬이며 대각 성분들이  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min(m,n)}$  특이값이며 큰 값부터 내림차순으로 정렬된 행렬이다.

### 7.1 Computing SVD

행렬  $\mathbf{A} \in \mathbb{R}^{m \times n}$ 에 대하여  $\mathbf{A} \mathbf{A}^T$ 와  $\mathbf{A}^T \mathbf{A}$ 는 다음과 같이 고유값분해할 수 있다.

$$\begin{aligned} \mathbf{A} \mathbf{A}^T &= \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T \mathbf{V} \mathbf{\Sigma}^T \mathbf{U}^T = \mathbf{U} \mathbf{\Sigma} \mathbf{\Sigma}^T \mathbf{U}^T = \mathbf{U} \mathbf{\Sigma}^2 \mathbf{U}^T \\ \mathbf{A}^T \mathbf{A} &= \mathbf{V} \mathbf{\Sigma}^T \mathbf{U}^T \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T = \mathbf{V} \mathbf{\Sigma}^T \mathbf{\Sigma} \mathbf{U}^T = \mathbf{V} \mathbf{\Sigma}^2 \mathbf{V}^T \end{aligned} \quad (30)$$

이 때 계산되는 행렬  $\mathbf{U}, \mathbf{V}$ 은 직교하는 고유벡터를 각 열의 성분으로 하는 행렬이며 대각행렬  $\mathbf{\Sigma}^2$ 의 각 성분은 항상 0보다 큰 양수의 값을 가진다. 그리고  $\mathbf{A} \mathbf{A}^T$ 와  $\mathbf{A}^T \mathbf{A}$ 를 통해 계산되는  $\mathbf{\Sigma}^2$ 의 값은 동일하다.

또한, 행렬  $\mathbf{A}$ 에 대하여  $\mathbf{A}\mathbf{A}^\top = \mathbf{A}^\top\mathbf{A} = \mathbf{S}$ 인 대칭행렬이 존재할 때  $\mathbf{S}$ 가 Positive (Semi-)Definite한 경우

$$\begin{aligned}\mathbf{x}^\top\mathbf{A}\mathbf{A}^\top\mathbf{x} &= (\mathbf{A}^\top\mathbf{x})^\top(\mathbf{A}^\top\mathbf{x}) = \|\mathbf{A}^\top\mathbf{x}\|^2 \geq 0 \\ \mathbf{x}^\top\mathbf{A}^\top\mathbf{A}\mathbf{x} &= (\mathbf{A}\mathbf{x})^\top(\mathbf{A}\mathbf{x}) = \|\mathbf{A}\mathbf{x}\|^2 \geq 0\end{aligned}\tag{31}$$

즉,  $\mathbf{A}\mathbf{A}^\top = \mathbf{U}\Sigma^2\mathbf{U}^\top$ 와  $\mathbf{A}^\top\mathbf{A} = \mathbf{V}\Sigma^2\mathbf{V}^\top$ 에서  $\Sigma^2$ 의 값은 항상 양수가 된다.

임의의 직각 행렬  $\mathbf{A} \in \mathbb{R}^{m \times n}$ 에 대하여 특이값 분해는 언제나 존재한다.  $\mathbf{A} \in \mathbb{R}^{n \times n}$  행렬의 경우 고유값 분해가 존재하지 않을 수 있지만 특이값 분해는 항상 존재한다. 대칭이면서 동시에 Positive Definite인 정방 행렬  $\mathbf{S} \in \mathbb{R}^{n \times n}$ 은 항상 고유값 분해값이 존재하며 이는 특이값 분해와 동일하다.

## 7.2 Range and nullspace of SVD

SVD는 다른 행렬 분해 방법들과 달리  $\mathbf{A}$ 가 Singular하거나 Near-Singular한 경우에도 사용할 수 있는 방법이다.  $\mathbf{A}$ 가 Non-Singular한 경우 역행렬은  $\mathbf{A}^{-1} = \mathbf{V} \cdot \text{diag}(1/\sigma_j) \cdot \mathbf{U}^\top$ 와 같이 계산할 수 있다. 만약  $\mathbf{A}$ 가 Singular한 경우 역행렬을 구할 때 몇몇  $\sigma_j = 0$ 이 되는데 이 때  $1/\sigma_j \Rightarrow 0$ 으로 설정함으로써 역행렬을 구할 수 있다. 특이값  $\sigma_j$ 와 관련하여 SVD 분해는 다음과 같은 성질을 갖는다.

- $\sigma_j \neq 0$  일 때 이와 상응하는  $\mathbf{U}$ 의 column들을  $\mathbf{A}$ 행렬의 Orthogonal set of basis vector of Range라고 한다.
- $\sigma_j = 0$  일 때 이와 상응하는  $\mathbf{V}$ 의 column들을  $\mathbf{A}$ 의 Orthogonal set of basis vector of Null Space라고 한다.
- 0이 아닌 특이값  $\sigma_j \neq 0$ 의 개수는 곧 행렬  $\mathbf{A}$ 의 rank와 같다.

## 7.3 SVD on under-determined system

$\mathbf{A}$ 가 Singular이면서 동시에  $\mathbf{b}$ 가 Range 안에 포함되는 경우 선형시스템은 다수의 해를 가진다. 이런 경우  $\mathbf{A}\mathbf{x} = \mathbf{b}$ 에서  $\|\mathbf{x}\|^2$ 가 최소가 되는 해를 구할 수 있다.

$$\begin{aligned}\min_{\mathbf{x}} \|\mathbf{x}\|^2 \\ \mathbf{x} = \mathbf{V} \cdot \text{diag}(1/\sigma_j) \cdot \mathbf{U}^\top \cdot \mathbf{b}\end{aligned}\tag{32}$$

## 7.4 SVD on over-determined system

$\mathbf{A}$ 가 Singular이면서 동시에  $\mathbf{b}$ 가 Range에 존재하지 않는 경우 선형시스템은 해가 존재하지 않는다. 이런 경우  $\|\mathbf{A}\mathbf{x} - \mathbf{b}\|$ 가 최소가 되는 근사해를 구할 수 있다.

$$\begin{aligned}\min_{\mathbf{x}} \|\mathbf{A}\mathbf{x} - \mathbf{b}\| \\ \mathbf{x} = \mathbf{V} \cdot \text{diag}(1/\sigma_j) \cdot \mathbf{U}^\top \cdot \mathbf{b}\end{aligned}\tag{33}$$

# 8 Pseudo inverse

Pseudo Inverse는 선형시스템에서 행렬  $\mathbf{A}$ 가 정방행렬이 아닐 경우 임의로 역행렬을 구하는 방법을 말한다. 이 때, 선형시스템은 일반적으로 full column rank 또는 full row rank일 때 pseudo inverse를 적용할 수 있다. Full rank가 아닌 행렬에 대한 pseudo inverse는 추후 섹션에서 설명한다.

## 8.1 Pseudo inverse on under-determined system

under-determined 시스템의 경우  $\mathbf{A}$ 는 full row rank가 되고 pseudo inverse는 다음과 같이 정의된다. Lagrange multiplier  $\lambda$ 를 포함하여 최적화 문제를 정의하면 다음과 같다.

$$\min_{\mathbf{x}} \|\mathbf{x}\|^2 + \lambda^\top(\mathbf{b} - \mathbf{A}\mathbf{x})\tag{34}$$

이를 미분 후 0으로 만드는 값을 찾으면 다음과 같다.

$$2\mathbf{x} - \mathbf{A}^\top\lambda = 0\tag{35}$$



$\mathbf{A}$ 가 정방행렬이 아니기 때문에 바로 해를 구할 수 없으므로 양변의 왼쪽에  $\mathbf{A}$ 를 곱한다.

$$2\mathbf{A}\mathbf{x} - \mathbf{A}\mathbf{A}^T\lambda = 0 \quad (36)$$

이 때,  $\mathbf{A}\mathbf{x} = \mathbf{b}$ 이므로 다음과 같은 식이 유도된다.

$$2\mathbf{b} = \mathbf{A}\mathbf{A}^T\lambda \quad (37)$$

$$\lambda = 2(\mathbf{A}\mathbf{A}^T)^{-1}\mathbf{b} \quad (38)$$

따라서  $\mathbf{x}$ 는 다음과 같이 구할 수 있다.

$$\mathbf{x} = \mathbf{A}^T(\mathbf{A}\mathbf{A}^T)^{-1}\mathbf{b} \quad (39)$$

$$\boxed{\mathbf{A}^\dagger = \mathbf{A}^T(\mathbf{A}\mathbf{A}^T)^{-1} \quad \dots \text{ for under-determined system}} \quad (40)$$

즉, under-determined 시스템에서 pseudo inverse는 오른쪽에 곱해지게 되며 이를 right pseudo inverse라고 부르기도 한다.

$$\begin{aligned} \mathbf{A}\mathbf{A}^\dagger\mathbf{x} &= \mathbf{A}^\dagger\mathbf{b} \\ \mathbf{x} &= \mathbf{A}^\dagger\mathbf{b} \\ \mathbf{x} &= \mathbf{A}^T(\mathbf{A}\mathbf{A}^T)^{-1}\mathbf{b} \quad \dots \text{ for under-determined system} \end{aligned} \quad (41)$$

## 8.2 Pseudo inverse on over-determined system

over-determined 시스템의 경우  $\mathbf{A}$ 는 full column rank가 되고 pseudo inverse는 다음과 같이 정의된다. 우선, over-determined 시스템에 대한 최적화 문제는 다음과 같이 최소제곱법 문제가 된다.

$$\min_{\mathbf{x}} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|^2 = \min_{\mathbf{x}} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|^2 = \min_{\mathbf{x}} (\mathbf{b} - \mathbf{A}\mathbf{x})^T(\mathbf{b} - \mathbf{A}\mathbf{x}) \quad (42)$$

이를 전개하면 다음과 같다.

$$\min_{\mathbf{x}} \mathbf{b}^T\mathbf{b} - \mathbf{b}^T\mathbf{A}\mathbf{x} - \mathbf{x}^T\mathbf{A}^T\mathbf{b} + \mathbf{x}^T\mathbf{A}^T\mathbf{A}\mathbf{x} \quad (43)$$

위 문제를 풀기 위해  $\mathbf{x}$ 에 대해 미분하면 다음과 같은 식이 얻어진다.

$$-(\mathbf{b}^T\mathbf{A})^T - (\mathbf{A}^T\mathbf{b}) + 2\mathbf{A}^T\mathbf{A}\mathbf{x} = 0 \quad (44)$$

따라서  $\mathbf{x}$ 는 다음과 같이 구할 수 있다.

$$\mathbf{x} = (\mathbf{A}^T\mathbf{A})^{-1}\mathbf{A}^T\mathbf{b} \quad (45)$$

$$\boxed{\mathbf{A}^\dagger = (\mathbf{A}^T\mathbf{A})^{-1}\mathbf{A}^T \quad \dots \text{ for over-determined system}} \quad (46)$$

즉, over-determined 시스템에서 pseudo inverse는 왼쪽에 곱해지게 되며 이를 left pseudo inverse라고 부르기도 한다.

$$\begin{aligned} \mathbf{A}^\dagger\mathbf{A}\mathbf{x} &= \mathbf{A}^\dagger\mathbf{b} \\ \mathbf{x} &= \mathbf{A}^\dagger\mathbf{b} \\ \mathbf{x} &= (\mathbf{A}^T\mathbf{A})^{-1}\mathbf{A}^T\mathbf{b} \quad \dots \text{ for over-determined system} \end{aligned} \quad (47)$$

## 8.3 SVD of pseudo inverse

선형 시스템  $\mathbf{A}\mathbf{x} = \mathbf{b}$ 이 주어졌을 때 임의의 직사각형 행렬  $\mathbf{A} \in \mathbb{R}^{m \times n}$ 와 pseudo inverse  $\mathbf{A}^\dagger$ 는 SVD 분해를 통해 다음과 같이 나타낼 수 있다.

$$\begin{aligned} \mathbf{A} &= \mathbf{U}\Sigma\mathbf{V}^T \\ \mathbf{A}^\dagger &= \mathbf{V}\Sigma^\dagger\mathbf{U}^T \end{aligned} \quad (48)$$

- $\mathbf{U} \in \mathbb{R}^{m \times m}$
- $\Sigma = \text{diag}(\sigma_1, \sigma_2, \sigma_3, \dots) \in \mathbb{R}^{m \times n}$
- $\Sigma^\dagger = \text{diag}(1/\sigma_1, 1/\sigma_2, 1/\sigma_3, \dots) \in \mathbb{R}^{n \times m}$
- $\mathbf{V} \in \mathbb{R}^{n \times n}$

### 8.3.1 Full column rank case

임의의 직사각형 행렬  $\mathbf{A} \in \mathbb{R}^{m \times n}$ 가 full column rank를 가지면 pseudo inverse는  $\mathbf{A}^\dagger \mathbf{A}$ 와 같이 왼쪽에 곱해진다. 이를 SVD 분해하여 표현하면 다음과 같다.

$$\mathbf{A}^\dagger \mathbf{A} = \mathbf{V} \Sigma^\dagger \mathbf{U}^\top \mathbf{U} \Sigma \mathbf{V}^\top = \mathbf{I}_n \quad (49)$$

또한, 앞서 구한 (46)에서  $\mathbf{A}^\dagger = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top$ 를 풀어쓰면 다음과 같다.

$$\begin{aligned} \mathbf{A}^\dagger &= (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= (\mathbf{V} \Sigma^\top \mathbf{U}^\top \mathbf{U} \Sigma \mathbf{V}^\top)^{-1} \mathbf{V} \Sigma^\top \mathbf{U}^\top \\ &= \mathbf{V} \Sigma^{-2} \Sigma \mathbf{U}^\top & \dots \Sigma^\top = \Sigma \\ &= \mathbf{V} \Sigma^\dagger \mathbf{U}^\top & \dots \Sigma^\dagger = \Sigma^{-1} \end{aligned} \quad (50)$$

이는 앞서 정의한 (48)와 동일하다.

### 8.3.2 Full row rank case

임의의 직사각형 행렬  $\mathbf{A} \in \mathbb{R}^{m \times n}$ 가 full row rank를 가지면 pseudo inverse는  $\mathbf{A} \mathbf{A}^\dagger$ 와 같이 오른쪽에 곱해진다. 이를 SVD 분해하여 표현하면 다음과 같다.

$$\mathbf{A} \mathbf{A}^\dagger = \mathbf{U} \Sigma \mathbf{V}^\top \mathbf{V} \Sigma^\dagger \mathbf{U}^\top = \mathbf{I}_m \quad (51)$$

또한, 앞서 구한 (40)에서  $\mathbf{A}^\dagger = \mathbf{A}^\top (\mathbf{A} \mathbf{A}^\top)^{-1}$ 를 풀어쓰면 다음과 같다.

$$\begin{aligned} \mathbf{A}^\dagger &= \mathbf{A}^\top (\mathbf{A} \mathbf{A}^\top)^{-1} \\ &= \mathbf{V} \Sigma^\top \mathbf{U}^\top (\mathbf{U} \Sigma \mathbf{V}^\top \mathbf{V} \Sigma^\top \mathbf{U}^\top)^{-1} \\ &= \mathbf{V} \Sigma \Sigma^{-2} \mathbf{U}^\top & \dots \Sigma^\top = \Sigma \\ &= \mathbf{V} \Sigma^\dagger \mathbf{U}^\top & \dots \Sigma^\dagger = \Sigma^{-1} \end{aligned} \quad (52)$$

이는 앞서 정의한 (48)와 동일하다.

### 8.3.3 Rank deficient case

만약 임의의 직사각형 행렬  $\mathbf{A}$ 이 full rank가 아닐 경우 pseudo inverse는 다음과 같이 나타낼 수 있다. 예를 들어  $\mathbf{A} \in \mathbb{R}^{3 \times 4}$  일 때 이를 SVD 분해하면 다음과 같다.

$$\begin{aligned} \mathbf{A} &= \mathbf{U} \Sigma \mathbf{V}^\top \\ &= \mathbf{U} \begin{bmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \mathbf{V}^\top \end{aligned} \quad (53)$$

Pseudo inverse  $\mathbf{A}^\dagger$ 를 SVD 분해하면 다음과 같다.

$$\begin{aligned} \mathbf{A}^\dagger &= \mathbf{V} \Sigma^\dagger \mathbf{U}^\top \\ &= \mathbf{V} \begin{bmatrix} 1/\sigma_1 & 0 & 0 \\ 0 & 1/\sigma_2 & 0 \\ 0 & 0 & 0 \end{bmatrix} \mathbf{U}^\top \end{aligned} \quad (54)$$

따라서 오른쪽 pseudo inverse  $\mathbf{A} \mathbf{A}^\dagger$ 는 다음과 같이 전개할 수 있다.

$$\begin{aligned} \mathbf{A} \mathbf{A}^\dagger &= \mathbf{U} \Sigma \mathbf{V}^\top \mathbf{V} \Sigma^\dagger \mathbf{U}^\top \\ &= \mathbf{U} \begin{bmatrix} 1 & & \\ & 1 & \\ & & 0 \end{bmatrix} \mathbf{U}^\top \\ &= \mathbf{u}_1 \mathbf{u}_1^\top + \mathbf{u}_2 \mathbf{u}_2^\top \end{aligned} \quad (55)$$

만약  $\mathbf{A}$ 가 full rank인 경우  $\mathbf{A}\mathbf{A}^\dagger$ 는 다음과 같다.

$$\begin{aligned}\mathbf{A}\mathbf{A}^\dagger &= \mathbf{I}_3 \\ &= \mathbf{u}_1\mathbf{u}_1^\top + \mathbf{u}_2\mathbf{u}_2^\top + \mathbf{u}_3\mathbf{u}_3^\top\end{aligned}\quad (56)$$

따라서 rank deficient 케이스의 경우  $\mathbf{A}\mathbf{A}^\dagger$ 는 마지막  $\mathbf{u}_3\mathbf{u}_3^\top$ 이 없는 pseudo inverse가 구해진다. 이는 항등행렬  $\mathbf{I}_3$ 와 유사한 값을 갖지만 동일하지는 않은 행렬이다.

다음으로 왼쪽 pseudo inverse  $\mathbf{A}^\dagger\mathbf{A}$ 는 다음과 같이 전개할 수 있다.

$$\begin{aligned}\mathbf{A}^\dagger\mathbf{A} &= \mathbf{V}\Sigma^\dagger\mathbf{U}^\top\mathbf{U}\Sigma\mathbf{V}^\top \\ &= \mathbf{V}\begin{bmatrix} 1 & & \\ & 1 & \\ & & \end{bmatrix}\mathbf{V}^\top \\ &= \mathbf{v}_1\mathbf{v}_1^\top + \mathbf{v}_2\mathbf{v}_2^\top\end{aligned}\quad (57)$$

만약  $\mathbf{A}$ 가 full rank인 경우  $\mathbf{A}^\dagger\mathbf{A}$ 는 다음과 같다.

$$\begin{aligned}\mathbf{A}^\dagger\mathbf{A} &= \mathbf{I}_4 \\ &= \mathbf{v}_1\mathbf{v}_1^\top + \mathbf{v}_2\mathbf{v}_2^\top + \mathbf{v}_3\mathbf{v}_3^\top + \mathbf{v}_4\mathbf{v}_4^\top\end{aligned}\quad (58)$$

따라서 rank deficient 케이스의 경우  $\mathbf{A}^\dagger\mathbf{A}$ 는 마지막  $\mathbf{v}_3\mathbf{v}_3^\top + \mathbf{v}_4\mathbf{v}_4^\top$ 이 없는 pseudo inverse가 구해진다. 이는 항등행렬  $\mathbf{I}_4$ 와 유사한 값을 갖지만 동일하지는 않은 행렬이다. 이는  $\mathbf{A}\mathbf{A}^\dagger$ 를 통해 구한 행렬보다 덜 항등행렬에 근접하다.

따라서 임의의 non-full rank를 가지는 직사각형 행렬  $\mathbf{A} \in \mathbb{R}^{m \times n}$ 이 주어졌을 때,  $m < n$ 인 경우  $\mathbf{A}\mathbf{A}^\dagger$ 를 수행하는 것이 더 항등행렬에 근접한 pseudo inverse를 수행할 수 있고  $m > n$ 인 경우  $\mathbf{A}^\dagger\mathbf{A}$ 를 수행하는 것이 더 항등행렬에 근접한 pseudo inverse를 수행할 수 있다.

## 8.4 QR decomposition of pseudo inverse when singular case

간혹  $\mathbf{A}^\top\mathbf{A}$ 가 singular하거나 near-singular한 경우 QR 분해를 사용하여 pseudo inverse를 구한다.

$$\begin{aligned}\mathbf{x} &= \mathbf{A}^\dagger\mathbf{b} \\ &= (\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top\mathbf{b} \\ &= (\mathbf{R}^\top\mathbf{Q}^\top\mathbf{Q}\mathbf{R})^{-1}\mathbf{R}^\top\mathbf{Q}^\top\mathbf{b} \\ &= (\mathbf{R}^\top\mathbf{R})^{-1}\mathbf{R}^\top\mathbf{Q}^\top\mathbf{b} \\ &= \mathbf{R}^{-1}\mathbf{Q}^\top\mathbf{b}\end{aligned}\quad (59)$$

위 식은 (27)와 동일하다.

## 9 Sherman-Morrison formula

역행렬이 존재하는 임의의 행렬  $\mathbf{A}$ 에 대해 rank 1 업데이트를 하는 방법을 Sherman-Morrison 공식이라고 한다. 해당 공식에 대한 보다 자세한 내용은 해당 강의를 참조하면 된다.

$$\boxed{(\mathbf{A} + \mathbf{u}\mathbf{v}^\top)^{-1} = \mathbf{A}^{-1} - \frac{\mathbf{A}^{-1}\mathbf{u}\mathbf{v}^\top\mathbf{A}^{-1}}{1 + \mathbf{v}^\top\mathbf{A}^{-1}\mathbf{u}}}\quad (60)$$

위 식에서  $(1 + \mathbf{v}^\top\mathbf{A}^{-1}\mathbf{u}) \neq 0$ 와  $(\mathbf{A} + \mathbf{u}\mathbf{v}^\top)^{-1}$ 이 역행렬이 존재하는 조건은 동치이다. 이 때,  $\mathbf{u}, \mathbf{v}$ 는 임의의 두 벡터를 의미하며 이를  $\mathbf{u}\mathbf{v}^\top$ 와 같이 곱하면 항상 rank 1 행렬이 생성된다.

$$\mathbf{u}\mathbf{v}^\top = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \begin{bmatrix} v_1 & v_2 \end{bmatrix} = \begin{bmatrix} v_1 & v_2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \cdots \text{linearly dependent} = \text{rank 1}\quad (61)$$

## 9.1 Recursive least squares

Sherman-Morrison 공식은 데이터가 계속 추가되는 최소제곱법 문제에 사용하면 연산량을 적게 소모하면서 효율적으로 역행렬을 업데이트할 수 있다. 다음과 같은 선형 시스템  $\mathbf{Ax} = \mathbf{b}$ 가 주어졌다고 하자.  $\mathbf{A} \in \mathbb{R}^{m \times n}$ ,  $\mathbf{x} \in \mathbb{R}^{n \times 1}$ ,  $\mathbf{b} \in \mathbb{R}^{m \times 1}$  일 때 이를 풀어쓰면 아래와 같다.

$$\mathbf{Ax} = \mathbf{b}$$

$$\begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_m^\top \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix} \quad (62)$$

선형시스템의 최소제곱법의 해는 다음과 같다.

$$\mathbf{x} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} \quad (63)$$

만약  $m+1$  번째 데이터  $\mathbf{a}_{m+1}^\top$ 이 입력되면 이에 맞게 최적해를 업데이트해줘야 한다. 표현의 편의를 위해  $m+1$  번째 데이터를  $\mathbf{a}$ 로 표현하면 다음과 같다.

$$\mathbf{x} = \left( \begin{bmatrix} \mathbf{A}^\top & \mathbf{a} \end{bmatrix} \begin{bmatrix} \mathbf{A}^\top \\ \mathbf{a} \end{bmatrix} \right)^{-1} \begin{bmatrix} \mathbf{A}^\top & \mathbf{a} \end{bmatrix} \begin{bmatrix} \mathbf{b} \\ b \end{bmatrix}$$

$$= (\mathbf{A}^\top \mathbf{A} + \mathbf{a}\mathbf{a}^\top)^{-1} (\mathbf{A}^\top \mathbf{b} + \mathbf{a}b_{m+1}) \quad (64)$$

이 때, 앞 부분  $(\mathbf{A}^\top \mathbf{A} + \mathbf{a}\mathbf{a}^\top)^{-1}$ 에 Sherman-Morrison 공식 (60)을 적용하면 연산량을 적게 소모하면서 효율적으로 최적해를 업데이트할 수 있다. 이는 다음과 같이 전개 후 치환하여 간결하게 나타낼 수 있다.

$$(\mathbf{A}^\top \mathbf{A} + \mathbf{a}\mathbf{a}^\top)^{-1} = (\mathbf{A}^\top \mathbf{A})^{-1} - \frac{(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{a}\mathbf{a}^\top (\mathbf{A}^\top \mathbf{A})^{-1}}{1 + \mathbf{a}^\top (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{a}}$$

$$= \mathbf{P} - \frac{\mathbf{P}\mathbf{a}\mathbf{a}^\top \mathbf{P}}{1 + \mathbf{a}^\top \mathbf{P}\mathbf{a}} \quad (65)$$

$$= \mathbf{P}_a$$

-  $(\mathbf{A}^\top \mathbf{A})^{-1} = \mathbf{P}$  표현의 편의를 위해 치환한다

위 치환한 식을 기반으로 (64)를 전개하면 다음과 같다.

$$(\mathbf{A}^\top \mathbf{A} + \mathbf{a}\mathbf{a}^\top)^{-1} (\mathbf{A}^\top \mathbf{b} + \mathbf{a}b_{m+1}) = \left( \mathbf{P} - \frac{\mathbf{P}\mathbf{a}\mathbf{a}^\top \mathbf{P}}{1 + \mathbf{a}^\top \mathbf{P}\mathbf{a}} \right) (\mathbf{A}^\top \mathbf{b} + \mathbf{a}b_{m+1})$$

$$= \mathbf{P}\mathbf{A}^\top \mathbf{b} + \frac{\mathbf{P}\mathbf{a}\mathbf{a}^\top \mathbf{P}}{1 + \mathbf{a}^\top \mathbf{P}\mathbf{a}} \mathbf{A}^\top \mathbf{b} + \mathbf{P}_a \mathbf{a} b$$

$$= \mathbf{x} - \frac{\mathbf{P}\mathbf{a}\mathbf{a}^\top \mathbf{P}}{1 + \mathbf{a}^\top \mathbf{P}\mathbf{a}} \mathbf{A}^\top \mathbf{b} + \mathbf{P}_a \mathbf{a} b \quad (66)$$

$$= \mathbf{x} - \left( \frac{\mathbf{P}\mathbf{a}}{1 + \mathbf{a}^\top \mathbf{P}\mathbf{a}} \right) \mathbf{a}^\top \mathbf{x} + \mathbf{P}_a \mathbf{a} b$$

$$= \mathbf{x} - (\mathbf{P}_a \mathbf{a}) \mathbf{a}^\top \mathbf{x} + \mathbf{P}_a \mathbf{a} b$$

$$= \mathbf{x} + \mathbf{P}_a \mathbf{a} (b - \mathbf{a}^\top \mathbf{x})$$

-  $\mathbf{P}\mathbf{A}^\top \mathbf{b} = \mathbf{x}$

위 식에서 5번째 줄은  $\mathbf{P}_a \mathbf{a}$ 를 전개한 후 분모를 통분하여 정리함으로써 유도할 수 있다. 따라서 데이터가 증가했을 때 새로운 최적해는 이전 최적해 식으로부터 아래와 같이 업데이트된다. 이를 recursive least squares(RLS)라고 한다.

$$\boxed{\mathbf{x} \leftarrow \mathbf{x} + \mathbf{P}_a \mathbf{a} (b - \mathbf{a}^\top \mathbf{x})} \quad (67)$$

## 10 Matrix inversion lemma

Matrix inversion lemma는 역행렬 변환 공식을 의미하며 선형 시스템을 다룰 때 자주 쓰이는 트릭 중 하나이다. 이는 Sherman-Morrison-Woodbury 공식이라고도 불린다. Matrix inversion lemma는 다음과 같이

정의된다. Lemma에 대한 보다 자세한 내용은 해당 강의를 참조하면 된다.

$$\boxed{(\mathbf{A} + \mathbf{UCV})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1}\mathbf{U}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})^{-1}\mathbf{VA}^{-1}} \quad (68)$$

- $\mathbf{A} \in \mathbb{R}^{n \times n}$
- $\mathbf{U} \in \mathbb{R}^{n \times k}$
- $\mathbf{C} \in \mathbb{R}^{k \times k}$
- $\mathbf{V} \in \mathbb{R}^{k \times n}$
- $\mathbf{A}, \mathbf{C}, \mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U}$  is invertible

## 10.1 Derivation of matrix inversion lemma

Matrix inversion lemma를 유도하기 위해 4개의 블록 행렬로 구성된  $\mathbf{M}$ 가 주어졌다고 하자.

$$\mathbf{M} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} \quad (69)$$

### 10.1.1 LDU decomposition

다음으로  $\mathbf{M}$ 를 LDU 분해하려고 한다. 아래와 같이  $\mathbf{C}$ 를 소거하기 위한 행렬을 곱해서 LU 행렬을 만들 수 있다.

$$\begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{CA}^{-1} & \mathbf{I} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{CA}^{-1} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} = \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{CA}^{-1} & \mathbf{I} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{0} & \mathbf{D} - \mathbf{CA}^{-1}\mathbf{B} \end{bmatrix} \quad (70)$$

이 때,  $\mathbf{D} - \mathbf{CA}^{-1}\mathbf{B}$ 를  $\mathbf{A}$ 의 schur complement ( $\mathbf{M}/\mathbf{A}$ )라고 한다. 다음으로 대각 행렬 성분만 남기기 위해 아래와 같이 오른쪽에 행렬을 전개하면 LDU 분해가 마무리된다.

$$\begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{CA}^{-1} & \mathbf{I} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{0} & \mathbf{D} - \mathbf{CA}^{-1}\mathbf{B} \end{bmatrix} = \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{CA}^{-1} & \mathbf{I} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0} & \mathbf{D} - \mathbf{CA}^{-1}\mathbf{B} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{A}^{-1}\mathbf{B} \\ \mathbf{0} & \mathbf{I} \end{bmatrix} \quad (71)$$

$\mathbf{M}^{-1}$ 은 다음과 같이 LDU 행렬을 사용하여 전개할 수 있다.

$$\boxed{\begin{aligned} \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix}^{-1} &= \begin{bmatrix} \mathbf{I} & -\mathbf{A}^{-1}\mathbf{B} \\ \mathbf{0} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{A}^{-1} & \mathbf{0} \\ \mathbf{0} & (\mathbf{D} - \mathbf{CA}^{-1}\mathbf{B})^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{C}^{-1}\mathbf{A} & \mathbf{I} \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{A}^{-1} + \mathbf{A}^{-1}\mathbf{B}(\mathbf{D} - \mathbf{CA}^{-1}\mathbf{B})^{-1}\mathbf{CA}^{-1} & -\mathbf{A}^{-1}\mathbf{B}(\mathbf{D} - \mathbf{CA}^{-1}\mathbf{B})^{-1} \\ -(\mathbf{D} - \mathbf{CA}^{-1}\mathbf{B})^{-1}\mathbf{CA}^{-1} & (\mathbf{D} - \mathbf{CA}^{-1}\mathbf{B})^{-1} \end{bmatrix} \end{aligned}} \quad (72)$$

### 10.1.2 UDL decomposition

행렬  $\mathbf{M}$  LDU 뿐만아니라 UDL로도 분해될 수 있다. 아래와 같이  $\mathbf{B}$ 를 소거하기 위한 행렬을 곱해서 UL 행렬을 만들 수 있다.

$$\begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{D}^{-1}\mathbf{C} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{D}^{-1}\mathbf{C} & \mathbf{I} \end{bmatrix}^{-1} = \begin{bmatrix} \mathbf{A} - \mathbf{BD}^{-1}\mathbf{C} & \mathbf{B} \\ \mathbf{0} & \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{D}^{-1}\mathbf{C} & \mathbf{I} \end{bmatrix}^{-1} \quad (73)$$

이 때,  $\mathbf{A} - \mathbf{BD}^{-1}\mathbf{C}$ 를  $\mathbf{D}$ 의 schur complement ( $\mathbf{M}/\mathbf{D}$ )라고 한다. 다음으로 대각 행렬 성분만 남기기 위해 아래와 같이 왼쪽에 행렬을 전개하면 UDL 분해가 마무리된다.

$$\begin{bmatrix} \mathbf{A} - \mathbf{BD}^{-1}\mathbf{C} & \mathbf{B} \\ \mathbf{0} & \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{D}^{-1}\mathbf{C} & \mathbf{I} \end{bmatrix}^{-1} = \begin{bmatrix} \mathbf{I} & \mathbf{BD}^{-1} \\ \mathbf{0} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{A} - \mathbf{BD}^{-1}\mathbf{C} & \mathbf{0} \\ \mathbf{0} & \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{D}^{-1}\mathbf{C} & \mathbf{I} \end{bmatrix}^{-1} \quad (74)$$

$\mathbf{M}^{-1}$ 은 다음과 같이 UDL 행렬을 사용하여 전개할 수 있다.

$$\boxed{\begin{aligned} \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix}^{-1} &= \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{D}^{-1}\mathbf{C} & \mathbf{I} \end{bmatrix} \begin{bmatrix} (\mathbf{A} - \mathbf{BD}^{-1}\mathbf{C})^{-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{D}^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{I} & -\mathbf{BD}^{-1} \\ \mathbf{0} & \mathbf{I} \end{bmatrix} \\ &= \begin{bmatrix} (\mathbf{A} - \mathbf{BD}^{-1}\mathbf{C})^{-1} & -(\mathbf{A} - \mathbf{BD}^{-1}\mathbf{C})^{-1}\mathbf{BD} \\ -\mathbf{D}^{-1}\mathbf{C}(\mathbf{A} - \mathbf{BD}^{-1}\mathbf{C})^{-1} & \mathbf{D}^{-1} + \mathbf{D}^{-1}\mathbf{C}(\mathbf{A} - \mathbf{BD}^{-1}\mathbf{C})^{-1}\mathbf{BD} \end{bmatrix} \end{aligned}} \quad (75)$$

### 10.1.3 Back to matrix inversion lemma

앞서 구한 (72), (75)는 분해 방법만 달랐을 뿐 모든 원소는 서로 같아야 한다. 따라서 첫번째 원소를 비교해보면 다음과 같다.

$$(\mathbf{A} - \mathbf{B}\mathbf{D}^{-1}\mathbf{C})^{-1} = \mathbf{A}^{-1} + \mathbf{A}^{-1}\mathbf{B}(\mathbf{D} - \mathbf{C}\mathbf{A}^{-1}\mathbf{B})^{-1}\mathbf{C}\mathbf{A}^{-1} \quad (76)$$

해당 식에서 아래와 같이 기호만 변경해주면 matrix inversion lemma 식 (68)가 된다.

$$\begin{aligned} \mathbf{B} &\rightarrow \mathbf{U} \\ \mathbf{C} &\rightarrow \mathbf{V} \\ \mathbf{D}^{-1} &\rightarrow -\mathbf{C} \\ \therefore (\mathbf{A} + \mathbf{UCV})^{-1} &= \mathbf{A}^{-1} - \mathbf{A}^{-1}\mathbf{U}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})^{-1}\mathbf{VA}^{-1} \end{aligned} \quad (77)$$

또한 (72), (75)의 두번째 원소를 비교하면 다음과 같다. 해당 식도 자주 사용되는 행렬 변환 트릭 중 하나이다.

$$\boxed{-\mathbf{A}^{-1}\mathbf{B}(\mathbf{D} - \mathbf{C}\mathbf{A}^{-1}\mathbf{B})^{-1} = -(\mathbf{A} - \mathbf{B}\mathbf{D}^{-1}\mathbf{C})^{-1}\mathbf{B}\mathbf{D}} \quad (78)$$

지금까지 소개한 matrix inversion lemma 행렬 변환 트릭은 칼만 필터(kalman filter)의 공식을 유도할 때 종종 사용되며 이외에도 많은 공학 분야에서 사용된다.

## 11 Reference

- [1] [blog] 선형대수학 (Linear Algebra) 개념 정리
- [2] [pdf] Pseudo Inverse 유도 과정
- [3] 혁펜하임님 유튜브 강의 영상

## 12 Revision log

- 1st: 2020-06-02
- 2nd: 2023-01-21
- 3rd: 2023-01-23
- 4th: 2024-02-08